何时更少的标签更有价值：
风险约束与延迟反馈下的学习

匿名作者

匿名机构

摘要 风险约束下的标签获取将模型学习与产生可观测结果的行动联系起来。在延迟反馈条件下，包含更多标签的可行集合，其学习价值可能低于覆盖不同信息方向的较小集合。本文通过同一状态下的数量与组成分解研究这一分离，并利用二维信息模型给出待反馈信息引起偏好反转的显式阈值。进一步地，我们区分结果揭示后的获取机会与标签到达前能够实现的价值。在此基础上提出 DC-PRISM：利用考虑待反馈信息的目标加权信息量，将可行集合与数量基准进行比较。在 128 个受控世界中，DC-PRISM 将平均 Brier 损失从 0.136683 降至 0.120234，平均获取标签数则从 6 降至 3.266。新一批受控比较确认了固定候选族完整规则相对数量基准与信息基准的收益。基于真实协变量的 256 对干预表明，覆盖缺口在四种设置中的三种扩大了事后机会，但策略收益仍未得到确认。四个已处理信贷队列上的十轮回放呈现异质性效果，其中 PPDai 上相对固定数量策略的 ALC-Brier 改善为 0.004139，并得到统计确认。这些结果将可行选择的信息几何与自适应获取的收益及适用边界联系起来。

关键词： 选择性标签 · 风险约束获取 · 延迟反馈 · 主动学习

1 引言

决策系统中的标签获取同时改变训练数据和系统对不利结果的风险敞口。例如，贷款机构只有授信后才能观察还款结果，被拒绝的申请则缺少标签。这种选择性标签结构使未来学习所能使用的数据依赖于过去的决策 [11,17]。当结果延迟到达时，学习器还必须考虑已经获批但尚未结清的申请。因此，获取问题同时涉及风险预算、总体覆盖不足，以及已经承诺获取但仍在等待反馈的信息。

风险预算决定哪些标签集合可行，但可行标签的数量并不决定预测价值。经典主动学习和实验设计依据观测对估计或预测的预期贡献选择样本 [5,21]。近期方法进一步显式优化基于 Fisher 信息的估计准则、预测信息或下游损失 [1,2,8]。这些目标强调集合组成：不同观测与目标总体的相关性，以及它们相对于已有数据的冗余程度，可能明显不同。风险约束引入额外相互作用，因为获取一个信息丰富但敞口较大的观测，可能挤占多个敞口较小观测的预算。待反馈信息又会改变比较结果，因为某些方向的信息已经确定将在未来到达。

本文以一个基准问题研究上述相互作用：何时较小的风险可行集合能够比数量导向的基准带来更大的学习价值？该基准固定操作性风险预算，使数量权衡可以显式比较。我们首先在同一信息状态下，将实现的预测收益分解为数量项与组成项；随后分析一个二维高斯信息模型。当待反馈信息沿基准集合的方向累积时，该方向上新增观测的价值下降，替代集合会在可计算的阈值之后变得更优。这说明，即使可行集合和预算保持不变，待反馈信息的方向也能改变选择决策。

这一机制的实际价值取决于能否在标签到达之前选好集合。我们区分训练结果揭示后的最优集合，以及仅根据可见信息能够作出的最优选择。该区分将预知结果的优势与决策前的选择质量分开，也解释了为什么事后机会增大时，策略收益仍可能很小。

据此，我们提出 DC-PRISM，以目标加权信息代理量将风险可行候选集合与数量基准进行比较。该策略纳入待反馈协变量，通过共享参数抽样评估相对价值，对标签数量减少施加惩罚，并在评分不足以支持偏离时保留基准。在 128 个原始受控世界中，DC-PRISM 的平均 Brier 损失为 0.120234，风险基准为 0.136683，同时前者获取的标签更少。新一批受控比较、256 对覆盖干预及四个队列上的延迟回放进一步检验这些收益如何随信息状态和数据集变化。

本文的贡献包括：

- 分析风险可行数量与预测价值之间的机制，结合同一状态下的数量与组成分解，给出方向性待反馈信息引起选择反转的显式条件。
- 建立连接受控收益、共同候选族比较和覆盖干预的分层实证研究，并通过事前与事后价值的区分解释机会诊断。
- 提出机制驱动的获取策略 DC-PRISM，在受控比较和四个已处理信贷队列的延迟回放中，按照固定预算及合法反馈时序进行评估。

2 问题设定与研究问题

在第 t 轮，学习器观察已标记历史 D_t、待反馈获取记录的协变量 O_t、未标记候选池 C_t 和目标协变量 Q_t。每个候选 i 具有可见的非负敞口 e_i，以及仅在获取后经过反馈延迟才揭示的不利二元结果 Y_i。选择时可用的信息记为 $\mathcal{H}_t$。合法策略仅使用 $\mathcal{H}_t$ 选择 $S_t \subseteq C_t$；O_t 和 C_t 中的结果仍然隐藏。常规获取独立于探索策略进入待反馈队列。

我们用 Brier 评分，即概率预测的均方误差，评价学习效果 [4]。对于固定状态，$L(S;Y)$ 表示在 $D \cup O \cup S$ 上拟合之后的测试损失，其中 Y 汇集选择时隐藏的训练结果。这一结清后终点比较从同一状态出发的不同集合。在线评价则仅使用每轮开始时已经释放的结果。两个终点分别回答集合价值和延迟策略表现这两个互补问题。

风险可行获取。 令 $q_i \in [0,1]$ 为选择时可用的风险分数，$\ell = \log(1/\alpha)$，并定义

$$\phi(q) = \begin{cases} q(1-q), & q \le 1/2, \\ 1/4, & q > 1/2. \end{cases} \tag{1}$$

对于非空集合 S，定义

$$\begin{aligned} \mu_U(S) &= \sum_{i \in S} e_i q_i, \qquad V_U(S) = \sum_{i \in S} e_i^2 \phi(q_i), \\ R_\alpha(S) &= \mu_U(S) + \sqrt{2 V_U(S) \ell} + \tfrac{1}{3} \ell \max_{i \in S} e_i. \end{aligned} \tag{2}$$

令 $R_\alpha(\varnothing) = 0$，并记 $\mathcal{A}_t = \{S \subseteq C_t : R_\alpha(S) \le B_t\}$。该包络通过平均损失、离散程度和最大敞口定义操作性的可行区域。

其概率解释来自标准的次伽马界 [3]。给定 $\mathcal{H}_t$，假设所选结果为相互独立的 Bernoulli 变量，且满足 $p_i \le q_{i\circ}$ 加权和 $Z_S = \sum_{i\in S} e_i Y_i$ 的均值不超过 $\mu_U(S)$，方差不超过 $V_U(S)$。令 $m = \max_{i\in S} e_i$，有

$$\log \mathbb{E}\Big[e^{\lambda(Z_S - \mathbb{E}Z_S)} \mid \mathcal{H}_t\Big] \le \frac{V_U(S)\lambda^2}{2(1-\lambda m/3)}, \quad 0 < \lambda < 3/m. \tag{3}$$

因此，Chernoff 优化给出 $\Pr\{Z_S > R_\alpha(S) \mid \mathcal{H}_t\} \le \alpha$。实验使用经验性的 Wilson/Laplace 风险分数；只有在上述同时上界覆盖条件与独立性条件成立时，该概率界才适用。

数量基准与研究问题。 我们构造基准 $M_K \in \mathcal{A}_t$，优先最大化基数，并以较小包络打破并列。小候选池通过枚举求解，较大候选池采用按敞口分层的可行搜索和基数上界。这里 $K = |M_K|$ 表示算法返回的可行数量。研究问题为：(i) 相对 M_K 的收益中，数量与组成各有何贡献；(ii) 待反馈信息何时使偏好的组成发生反转；(iii) 策略能够在结果揭示前利用多少已观察到的机会？DC-PRISM 用目标加权信息评分将候选集合与 M_K 比较，以处理第三个问题；第 5 节给出具体规则。

3 机制分析

3.1 数量与组成

对于选定集合 S，设其大小为 $k \le K$，令 M_k 为大小为 k、按风险排序的可行基准；当 $k = K$ 时直接使用 M_K。三个模型均从相同的 $D \cup O$ 出发，并使用相同的已实现结果。定义

$$\begin{aligned} Q_k &= L(M_k; Y) - L(M_K; Y), \\ C_k &= L(M_k; Y) - L(S; Y), \\ J &= L(M_K; Y) - L(S; Y) = C_k - Q_k. \end{aligned} \tag{4}$$

数量项比较两个风险基准，组成项比较大小相同的集合。$J > 0$ 表示组成收益超过数量项。Q_k 的符号取决于拟合模型与已实现标签：更大的基准集合也可能具有更高的测试损失。

风险将标签数量与信息方向耦合起来，因为一个信息丰富的观测可能挤占多个成本较低的观测。待反馈信息进一步引入替代关系：在 D 中尚未覆盖的方向，可能已经由 O 中的记录代表。

3.2 方向性待反馈信息

考虑一个二维线性高斯模型，其精度矩阵为 $H = \mathrm{diag}(h_1, h_2)$，目标权重为 $G = \mathrm{diag}(g_1, g_2)$,所有对角元素均为正。学习损失为加权后验预测方差 $\mathrm{tr}(GH^{-1})$。待反馈观测在方向 1 上增加精度 $o \ge 0$。有两种可行动作：数量基准在方向 1 上增加总精度 $a > 0$，较小的替代集合在方向 2 上增加精度 $b > 0$。当 o 改变时，两者的风险可行性保持不变。

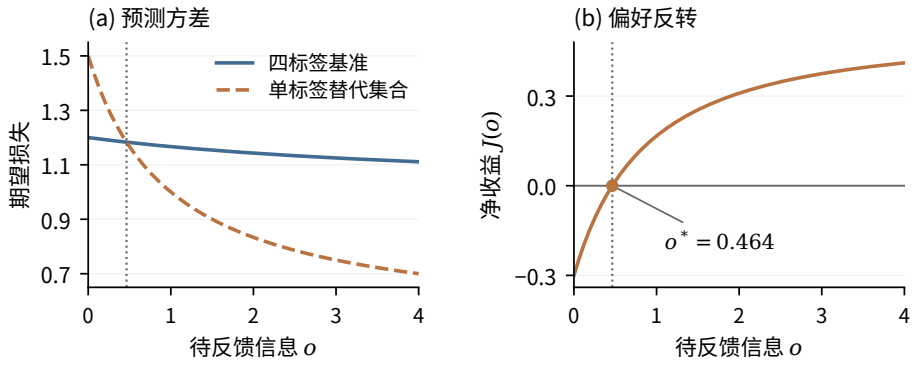


图 1. 二维高斯模型中的解析偏好反转。两个动作满足同一固定风险预算。随着待反馈信息沿四标签基准方向累积，单标签替代集合在 $o^* \approx 0.464$ 后变得更优。损失为加权后验预测方差。

命题 1 (方向性偏好反转). 选择替代集合而非数量基准的收益为

$$J(o) = \frac{g_2 b}{h_2(h_2+b)} - \frac{g_1 a}{(h_1+o)(h_1+o+a)}. \tag{5}$$

该收益随 o 严格增加。令 $v_2 = g_2 b/[h_2(h_2+b)]$，则替代集合更优当且仅当

$$o > o^* = \frac{-a + \sqrt{a^2 + 4g_1 a/v_2}}{2} - h_1. \tag{6}$$

当 $o^* > 0$ 时，在 $o \geq 0$ 范围内发生偏好反转。

证明. 基准的损失为 $g_1/(h_1+o+a) + g_2/h_2$，替代集合的损失为 $g_1/(h_1+o) + g_2/(h_2+b)$。两者相减即得式 (5)。其导数为 $g_1 a[2(h_1+o)+a]/[(h_1+o)^2(h_1+o+a)^2] > 0$。求解 $(h_1+o)(h_1+o+a) > g_1 a/v_2$ 即得式 (6)。

这种反转可以在敞口预算不变时发生。取 $h_1 = h_2 = g_1 = g_2 = 1$，比较方向 1 上的四个单位信息标签与方向 2 上的一个单位信息标签，即 $a = 4$、$b = 1$。令 $\alpha = 0.1$，共同风险分数为 $q = 0.1$，每个基准标签的敞口为 0.1，替代标签的敞口约为 0.16244812，则两个动作的包络均为 $B \approx 0.24551080$。将替代标签与任意一个基准标签合并就会超过 B。这些敞口值独立于高斯信息模型，用于规定动作的可行性。

当 $o = 0$ 时，基准与替代集合的损失分别为 1.2 和 1.5；当 $o = 1$ 时，两者分别为 1.166667 和 1.0。图 1 展示了 $o^* \approx 0.464102$ 处的转变。其机制是方向性冗余：待反馈信息降低了基准轴上新增观测的价值，而另一轴上的增量价值保持不变。该阈值描述的是这一对角模型，并启发我们根据历史信息与预期待反馈信息共同评价候选集合。

3.3 结果揭示前后的机会

看到训练结果后的最优集合，未必是结果到达前的最优决策。固定可见信息 $\mathcal{H}$ 和包含基准 M 的有限候选族 $\mathcal{F}$。令 $L(S,Y)$ 对测试结果取平均，但保留对隐藏训练标签 Y 的依赖。定义

$$H_{\mathrm{post}} = \mathbb{E}\left[L(M,Y) - \min_{S\in\mathcal{F}} L(S,Y) \mid \mathcal{H} \right], \tag{7}$$

$$H_{\mathrm{pre}} = \mathbb{E}[L(M,Y) \mid \mathcal{H}] - \min_{S\in\mathcal{F}} \mathbb{E}[L(S,Y) \mid \mathcal{H}]. \tag{8}$$

由于最小值的期望不大于期望的最小值，有 $H_{\mathrm{post}} \geq H_{\mathrm{pre}} \geq 0$。对于任意合法的族内策略，设其期望收益为 G_π，则

$$H_{\mathrm{post}} - G_\pi = \underbrace{H_{\mathrm{post}} - H_{\mathrm{pre}}}_{\text{预知结果的优势}} + \underbrace{H_{\mathrm{pre}} - G_\pi}_{\text{结果揭示前的选择差距}} . \tag{9}$$

经验性的候选族最小损失衡量的是给定已实现训练标签后的机会。即使额外的事前价值很小，该机会也可能增大。后文的覆盖干预将使用这一区分。

4 受控实验证据

4.1 受控选择收益

设计。 每个合成世界有六个特征、80 个历史标签、22 条待反馈获取记录、24 个候选、180 条目标协变量记录和 240 个测试观测。历史数据对候选方向的覆盖较窄。候选组包含低风险核心观测、与待反馈方向一致的观测、沿另外两个预测方向的观测，以及辅助特征尾部观测。不同组的敞口范围不同。待反馈观测集中在第二特征方向，而目标分布还覆盖第三和第四方向。结果由固定的 Bernoulli 模型生成，其中包含逻辑回归核心和分段的辅助特征尾部效应。这一设计同时提供冗余和互补的可行获取选项。

同一世界内的所有集合选择共享历史、候选池、风险分数和数值预算。选择固定后，标签才用于评价。我们先分析 128 个原始世界，再用 128 个新世界开展共同候选族比较。第二项研究还包含四种使用生成结果的真实协变量设置，共形成 35 项已注册主要比较。我们报告配对均值差、95% Bonferroni 同时 t 区间及 Holm 校正检验 [7]。当同时区间下端超过 10^{-4} Brier 时，收益被判定为实质性正向。世界数量和比较族均在运行相应批次之前固定。

已实现学习中的数量与组成。 在两批受控世界中，DC-PRISM 均以更少的标签获得更低的 Brier 损失（表 1）。原始世界中，其平均损失为 0.120234，Safe-MinRisk 为 0.136683，对应平均数量分别为 3.266 和 6。修复后的固定数量规则达到四标签目标，损失为 0.136720；其相对 DC-PRISM 的配对超额损失为 0.016486，逐项 95% 区间为 $[0.010972, 0.022001]$。

同一状态分解得到 DC-PRISM 的平均 $C_k = 0.016262$、$Q_k = -0.000187$ 和 $J = 0.016449$。主要收益来自在所选基数下，用不同组成的集合替换风险排序集合。数量项为微小负值，说明较小风险基准在这些已实现拟合中本身也略优。这将观察到的收益与组成联系起来，同时不预设每一次减少数量都会付出损失代价。

表 1. 两批各含 128 个受控世界的结清后 Brier 与平均获取数量。原始批次的固定数量行使用修复后的四标签规则；新批次使用五标签及共同候选族中的点值选择。两个批次中的 DC-PRISM 均保留完整搜索。

	原始世界		新世界	
策略	Brier ↓	标签数	Brier ↓	标签数
Safe-MinRisk	0.136683	6.000	0.147046	6.000
固定数量	0.136720	4.000	0.141038	5.000
Fisher-cost	0.143776	2.719	0.153765	2.680
DC-PRISM	0.120234	3.266	0.130807	3.203
共同候选族 Full	–	–	0.134644	4.352

共同候选族比较。 为在相同备选集合上比较评分组件，我们构造不使用待反馈信息的候选族，并加入 M_K 在每个基数下的可行前缀。随后按待反馈信息、低分位数或高分位数、数量惩罚、回退门控这四项因素的 16 种组合重新评分。完整配置记为 *Full*。Full、固定数量和评分对照共享该候选族；Fisher-cost 在相同状态、风险分数和预算下使用自身的装包规则。DC-PRISM 保留完整搜索。共同候选族中的固定数量规则在大小 $\lceil 0.75K \rceil$ 下最大化点值。

在新受控世界中，Full 的平均 Brier 为 0.134644，平均数量为 4.352。其相对固定数量、Safe-MinRisk 和 Fisher-cost 的收益分别为 0.006394、0.012402 和 0.019121；三个同时区间的下端均超过实质性阈值（图 2）。DC-PRISM 完整搜索的描述性平均损失为 0.130807，平均标签数为 3.203。

单项评分对比的结果不如完整策略比较明确。低分位数和待反馈重新评分的收益均值分别为 0.003885 和 0.003044，但同时区间均跨越零。门控和数量惩罚的均值分别为 -0.000007 和 -0.000238，区间也跨越零。这些结果确认了完整选择规则在该受控条件下的收益，但四个单独组件的效果仍未确定。

4.2 历史覆盖与机会

连接真实协变量。 我们保留 HMEQ 和 LendingClub 的观测协变量，并由以下模型生成标签：线性设置为 $p(x) = \sigma(-0.8 + x^\top \beta)$，其中 $\beta = (0.45, 0.65, -0.5, 0.35, 0.2, -0.15)$；非线性设置则在 logit 上增加 $0.5 \sin(x_2) + 0.35 x_3 x_4$。四种设置各含 64 个世界。中位数填补与缩放在历史样本上拟合；辅助坐标予以保留，不作尾部铰链变换。共同候选族 Full 相对 Safe-MinRisk 的平均收益范围为 -0.000038 至 0.000036，未确认实质性优势。候选族的平均事后改进空间从受控生成器中的约 0.0205 降至这些设置中的 0.0016–0.0018。

配对覆盖干预。 接下来，我们固定基准决策问题，只改变历史覆盖。每个新世界的储备池包含 240 条随机抽取记录。广覆盖组使用前 80 条，缺口组使用变换后第二特征值最低的 80 条。两组的候选、待反馈、目标和测试记录，及其生成标签、预处理、风险分数、数值预算、基准和候选族均相同。预处理、风险计算与候选族构造仅使用广覆盖基准历史完成一次，而预测学习器分别在各组历史上拟合。因此，该干预在冻结的基准决策问题条件下隔离历史覆盖的影响。

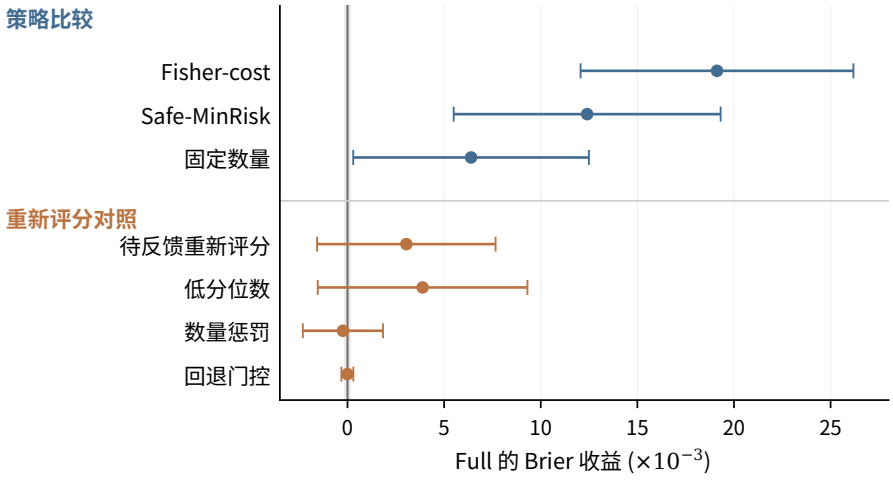


图 2. 128 个新受控世界中的 Full：对照方法减去 Full 的 Brier 损失，以及针对 35 项比较构造的 95% 同时区间。评分对照和固定数量共享 Full 的候选族；Fisher-cost 使用自身装包规则。灰色带表示 $\pm 10^{-4}$ Brier。

该研究在每种设置中另取 64 对世界，共 256 对。主要终点为固定测试协变量上的期望 Brier：

$$L_p(S;Y) = \frac{1}{|T|}\sum_{j\in T}\left[(\widehat{p}_{S,j} - p_j)^2 + p_j(1-p_j)\right], \tag{10}$$

该指标对测试标签的随机性积分，同时保留已实现训练结果。16 项主要比较构成独立的同时推断比较族。

覆盖缺口在三种设置中使事后改进空间分别增加 0.002320、0.002391 和 0.002312，对应同时区间下端为 0.000622、0.000756 和 0.000753（图 3）。HMEQ 非线性结果设置的平均增加量为 0.002726，区间为 $[-0.000061, 0.005513]$。四种设置中，Full 在缺口组的收益均未得到确认；LendingClub 非线性设置的区间完全位于 $\pm 10^{-4}$ 内。

历史覆盖改变了哪些已实现集合表现最好，但 Full 相对风险基准的收益仍很小。式 (9) 将预知隐藏训练标签的优势与结果揭示前选择不充分造成的差距分开；保存的候选族最小损失衡量的是二者共同形成的效果。

5 机制驱动的获取策略

5.1 目标加权信息

DC-PRISM 近似评价待反馈记录结清后，可行集合带来的增量价值。我们在 D 上拟合 ℓ_2 正则化逻辑回归，记 $\bar{x} = (1, x^\top)^\top$、$p_\theta(x) = \sigma(\bar{x}^\top\theta)$ 和 $w_\theta(x) =$

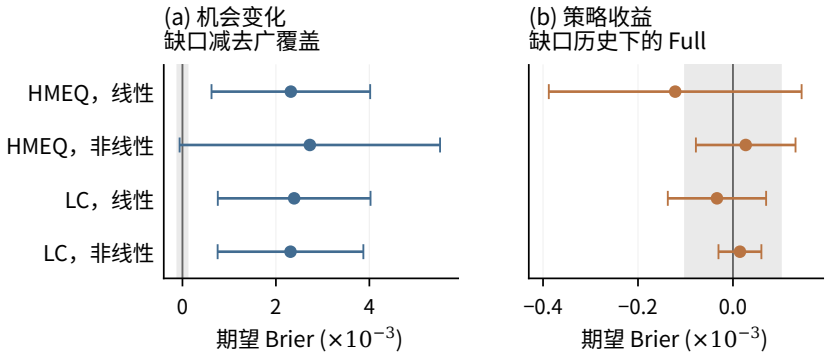


图 3. 覆盖干预，每种设置有 64 对世界。左：由广覆盖历史变为缺口历史时，候选族事后改进空间的变化。右：缺口历史下 Full 相对风险基准的收益。误差线为 16 项比较族的 95% 同时区间。两个面板的横轴尺度不同；灰色带表示 $\pm 10^{-4}$ 期望 Brier。LC 表示 LendingClub。

$p_\theta(x)[1-p_\theta(x)]$。信息矩阵与目标矩阵为

$$H_{D+O}(\theta) = \Lambda + \sum_{i \in D \cup O} w_\theta(x_i)\bar{x}_i\bar{x}_i^\top, \tag{11}$$

$$G_Q(\theta) = \frac{1}{|Q|}\sum_{j \in Q} w_\theta(x_j)^2\bar{x}_j\bar{x}_j^\top, \tag{12}$$

$$A_S(\theta) = \sum_{i \in S} w_\theta(x_i)\bar{x}_i\bar{x}_i^\top. \tag{13}$$

矩阵 G_Q 按目标预测的敏感度对参数不确定性加权，由此得到局部二次近似下的 Brier 降低代理量：

$$V_\theta(S) = \operatorname{tr}\left[G_Q(\theta)\{H_{D+O}(\theta)^{-1} - (H_{D+O}(\theta) + A_S(\theta))^{-1}\}\right]. \tag{14}$$

这种目标加权沿用实验设计 [21] 和基于信息的获取 [1,2] 所强调的预测目标。待反馈协变量进入信息矩阵，但其标签并不揭示。在二维模型中，这一操作降低了已覆盖方向的新增价值。

5.2 相对于可行基准的选择

候选族包含 M_K、依据边际效用与边际包络成本之比构造的可行前缀、按价值排序的前缀，以及保留部分 M_K 后填入其他候选的交换集合。保守与乐观曲率排序为搜索提供不同方向。每个提议集合均按式 (2) 检查。受控研究的枚举截断为 16 个候选，回放为 14 个；更大候选池使用分层前缀搜索、局部交换和数量上界。当上界与已找到数量一致时，可以认证基准数量，而风险并列处理仍为启发式。

表 2. 用于回放的已提供处理后队列，各含六个输入特征和记录的二元结果。敞口根据初始历史归一化后进入获取约束。

队列	行数	正标签比例（%）	敞口字段
HMEQ	5,960	19.95	贷款金额
LendingClub	10,624	20.70	贷款本金
PPDai	55,596	12.92	授信额度
UCI Credit	30,000	22.12	信用卡额度

通过共享参数抽样，在相同模型不确定性下比较提议集合。采用局部高斯近似 [12]，抽取 $\theta^{(m)} \sim \mathcal{N}(\widehat{\theta}, H_D^{-1})$。对于候选信息，使用阻尼曲率

$$\widetilde{w}_i^{(m)} = w_{\theta^{(m)}}(x_i)\exp\Big[-0.45\{\bar{x}_i^{\top}(\theta^{(m)}-\widehat{\theta})\}^2\Big]. \tag{15}$$

令 $\widetilde{V}_m$ 表示使用每次抽样对应矩阵的式 (14)，其中候选曲率下限为 10^{-6}。设 $a_m = \max\{\widetilde{V}_m(M_K), 10^{-6}\}$，并定义

$$d_m(S) = \tanh\!\left(\frac{\widetilde{V}_m(S) - a_m}{2.5 a_m}\right), \tag{16}$$

$$Z(S) = \widehat{\mathrm{quantile}}_{0.2}\{d_m(S)\} - 0.22\frac{(K-|S|)_+}{\max(K,1)}. \tag{17}$$

若 Z 的最大值超过 0.08，则选择对应集合，否则选择 M_K。经验分位数概括参数不确定性；惩罚和门控要求标签更少的选择相对基准具有足够的改进。

构造 q 时，我们取拟合历史风险较高的一半记录，计算单侧 Wilson 上界率（$z = 1.645$）。将该上界率截断在这些记录的平均拟合风险与 0.98 之间，计算其与该均值的 logit 差，并将位移截断在 $[0.15, 1.15]$。将该位移加到 40 次 Laplace 抽样的 logit 上，取 0.9875 分位数，经 sigmoid 后截断到 $[10^{-6}, 0.999]$。这些风险抽样独立于效用抽样。对于 F 个提议集合、M 次抽样和 d 个模型参数，评分中矩阵求逆的成本为 $O(MFd^3)$；抽样矩阵在集合间复用。实验使用六个特征与一个截距，斜率正则化为 0.45，信息矩阵中的截距岭项为 10^{-4}。受控研究使用 20 次参数抽样，在线回放使用 16 次。新回放中所有评分参数保持固定。

6 真实队列回放

6.1 数据与延迟协议

我们使用一份固定的已提供数据归档，其中包含标记为 HMEQ、LendingClub、PPDai 和 UCI Credit 的六特征处理后队列（表 2）。HMEQ 房屋净值贷款数据、LendingClub 贷款记录和 UCI 信用违约数据提供了相应的应用来源 [15,6,20]。回放使用归档记录的二元结果与敞口字段。队列名称标识这些已提供的处理后输入；文中所有样本量和特征数均指该归档。

对于每个队列与种子，我们保留 1,000 条测试记录、600 条未标记目标记录，以及与之不相交的 600 条历史储备记录。依据协变量排序的规则选择 68 条初始

历史记录。其余记录形成构造的数据流：每轮包含 24 个候选和 14 条常规获取记录，按可观测特征与敞口排序选择，再在指定组内随机化。数据流提供低风险、与待反馈方向一致、互补和尾部观测。每个队列使用 16 个新的随机划分与数据流种子。因此，评估以四个固定队列及指定的数据流构造为条件。

预处理在初始 68 条记录上拟合，包括中位数填补、标准化、截断至 ± 4.5，以及对最后两个坐标实施尾部铰链变换。铰链阈值使用初始历史的第 90 百分位数，下限为 1.35，尺度为 1.85。敞口按初始第 5 和第 95 百分位数缩尾，再除以缩尾后的均值。使用初始基准模型固定各策略共享的数值预算：按共同风险与离散程度评分排序取六个候选，其包络的 1.03 倍即为预算。回放期间，各策略根据自身已释放结果更新学习器和经验 q。

探索标签在选择后一个轮次到达，常规标签在两个轮次后到达。每轮开始时释放到期结果，并在本轮新获取记录揭示标签之前测量 Brier 损失。待反馈状态包含未释放队列与本轮常规获取记录。主要指标为

$$\text{ALC-Brier} = \frac{1}{10}\sum_{t=1}^{10}\frac{1}{|T|}\sum_{j\in T}(Y_j - \widehat{p}_{t,j})^2. \tag{18}$$

各方法共享初始数据、外部数据流、目标与测试集、预算序列、模型类别和反馈时序。后续历史则随各自获取行为而分化。

我们将 DC-PRISM 与四个基准比较。仅常规获取不额外获取标签。*Safe-MinRisk* 选择可行数量基准。固定数量以 $\lceil 0.75K \rceil$ 个标签为目标，按点值与成本之比排序；若贪心装包未达到该数量，则回退到锚点子集。*Fisher-cost* 使用 $G = I$，按单个观测带来的未加权参数方差降低量除以敞口风险成本排序，再按初始排序贪心填入可行候选，不更新排序。这就是本文实现的 Fisher 信息基准。每个队列相对 Safe-MinRisk、固定数量和 Fisher-cost 的三项比较，共组成 12 项主要检验。方法按种子配对；同时区间与 10^{-4} 实质性阈值沿用受控研究的约定。

6.2 在线结果

在线结果因队列而异（表 3）。DC-PRISM 的平均 ALC-Brier 在四个队列上均低于 Safe-MinRisk，改善范围从 UCI Credit 的 0.000124 到 PPDai 的 0.006090。其均值在 HMEQ、LendingClub 和 PPDai 上低于固定数量，在 UCI Credit 上近乎相同。Fisher-cost 在 HMEQ、LendingClub 和 UCI Credit 上的平均损失更低；DC-PRISM 在 PPDai 上更低。

主要同时区间识别出一项实质性正向比较：在 PPDai 上，DC-PRISM 相对固定数量改善 0.004139，区间为 $[0.000518, 0.007759]$，Holm 校正后 $p = 0.018599$。其余 11 个区间均包含零（表 4）。因此，回放支持特定队列上的改善，而其余配对效果仍存在不确定性。

获取数量有助于解释这些差异。在每个队列中，DC-PRISM 每轮选择的标签均少于 Safe-MinRisk，但减少量从 UCI Credit 的 0.806 到 LendingClub 的 2.419 不等。在 PPDai 上，其数量 5.419 接近固定数量策略的 5.556，而平均预测损失相差 0.004139。在 HMEQ 上，Fisher-cost 选择 3.125 个标签，少于 DC-PRISM 的 4.319，且平均损失更低。两种模式均说明，应当同时考察组成与数量。

DC-PRISM 在各队列上的平均风险包络利用率为 0.964–0.978。四个选择非空集合且受包络约束的方法，在这些运行中均未记录到包络违规或已实现预算

表 3. 四个已提供信贷队列上的十轮回放。ALC 为到期反馈到达后、本轮选择前测量的 Brier 评分均值。标准差描述划分与数据流的变异。在共享数据流和数值预算下，各策略的历史分别演化。

策略	HMEQ	LendingClub	PPDai	UCI Credit
在线 ALC-Brier 均值 ↓（16 个种子的标准差）				
仅常规获取	0.1733 (0.0317)	0.1672 (0.0143)	0.1398 (0.0244)	0.1731 (0.0224)
Safe-MinRisk	0.1723 (0.0312)	0.1666 (0.0134)	0.1351 (0.0161)	0.1725 (0.0228)
固定数量	0.1719 (0.0314)	0.1666 (0.0137)	0.1331 (0.0129)	0.1724 (0.0230)
Fisher-cost	0.1654 (0.0273)	0.1653 (0.0135)	0.1306 (0.0122)	0.1719 (0.0256)
DC-PRISM	0.1687 (0.0330)	0.1657 (0.0100)	0.1290 (0.0117)	0.1724 (0.0244)
每轮平均选择标签数				
Safe-MinRisk	6.537	6.319	6.844	7.444
固定数量	5.362	5.256	5.556	6.000
Fisher-cost	3.125	3.119	3.825	5.344
DC-PRISM	4.319	3.900	5.419	6.638

超额。这些是归一化敞口下的回放频率。全部 6,400 条轮次记录均通过时序、不相交性及固定数量检查；重新回放 80 条轨迹，对应 800 条被检查记录完全复现。

受控比较在共同状态下隔离集合选择的影响；在线回放则联合评价获取、延迟更新和随时间变化的估计。两类结果的差异指出了实际挑战：如何把有利的可行集合组成转化为有收益的连续决策。

7 相关工作

面向预测的获取与批量获取。 统计主动学习通过选择观测改进预测模型 [5]。直推式实验设计将未标记目标总体纳入选择准则 [21]；BAIT 利用 Fisher 嵌入优化最大似然估计误差的一个界 [1]。EPIG 衡量预测中的信息增益 [2]，损失驱动的贝叶斯主动学习则从下游决策损失推导获取目标 [8]。BatchBALD 通过联合互信息处理同时获取标签之间的依赖 [10]。这些工作为本文提供预测与几何基础。本文分析敞口可行区域如何与待反馈信息相互作用，从而改变数量与组成的相对价值。Fisher-cost 实现的是第 6 节定义的静态迹降低量与成本之比基准。

成本、选择性标签与延迟反馈。 成本敏感主动学习研究如何分配异质标注投入 [16]，ConBatch-BAL 则在预算约束下构造批次 [13]。在决策系统中，标签获取成本也可能来自揭示结果的行动本身。选择性标签研究形式化了由此产生的观测问题 [11]；Wei 研究平衡学习成本与未来效用的策略 [17]，Keswani 等将探索与假阳性比例及群体覆盖约束结合 [9]。利用日志数据的主动学习借助历史观测指导后续实验 [19]。Pham 等通过模拟查询标签到达时可用的训练数据处理验证延迟 [14]。本文的决策状态同时包括常规待反馈结果与先前探索的待反馈结果。固定该状态及风险预算，可以直接比较不同可行组成。

统计基础与信贷预测。 矩阵代理量与参数扰动建立在贝叶斯学习的局部高斯近似之上 [12]。风险包络采用次伽马集中界构造 [3]；经验风险分数结合 Wilson 调

表 4. DC-PRISM 在在线 ALC-Brier 上的主要配对收益，单位为 10^{-3}。正值有利于 DC-PRISM。区间为覆盖全部 12 项比较的 95% Bonferroni 同时区间；在该单位下，实质性阈值为 0.1。

队列	对照方法	收益 ↑	同时区间
HMEQ	Safe-MinRisk	+3.624	[-3.219, +10.468]
	固定数量	+3.256	[-3.477, +9.989]
	Fisher-cost	-3.288	[-11.100, +4.524]
LendingClub	Safe-MinRisk	+0.945	[-3.632, +5.523]
	固定数量	+0.939	[-3.931, +5.809]
	Fisher-cost	-0.416	[-5.681, +4.849]
PPDai	Safe-MinRisk	+6.090	[-0.834, +13.014]
	固定数量	+4.139	[+0.518, +7.759]
	Fisher-cost	+1.605	[-1.002, +4.212]
UCI Credit	Safe-MinRisk	+0.124	[-2.362, +2.610]
	固定数量	-0.028	[-2.471, +2.415]
	Fisher-cost	-0.464	[-2.739, +1.811]

整 [18] 与参数抽样分位数。预测评价使用 Brier 评分 [4]，已注册比较族同时采用 Holm 校正检验 [7] 和同时区间。信贷违约概率估计为这些区分提供了自然应用 [20]。我们的比较共同规定目标协变量、历史覆盖、敞口约束与未来标签的可见性，从而区分已实现集合价值和结果揭示前的决策价值。

8 结论

风险约束下的标签获取需要比较可行集合提供的信息，并计入已经处于待反馈状态的信息。同一状态下的数量与组成分解使这一权衡显式化；二维模型给出待反馈信息使较小替代集合变得更优的阈值。受控研究展示了以更少获取取得明显收益的情形，而覆盖干预则区分了事后机会与选择规则实际实现的改善。DC-PRISM 将这些分析转化为基于可行基准的策略，并在信贷队列延迟回放中表现出异质性收益。后续研究方向是更直接地估计结果揭示前的学习价值，使有利的信息几何能够转化为可靠的获取决策。

参考文献

1. Ash, J., Goel, S., Krishnamurthy, A., Kakade, S.: Gone fishing: Neural active learning with Fisher embeddings. In: Advances in Neural Information Processing Systems. vol. 34, pp. 8927–8939 (2021), https://proceedings.neurips.cc/paper_files/paper/2021/hash/4afe044911ed2c247005912512ace23b-Abstract.html
2. Bickford Smith, F., Kirsch, A., Farquhar, S., Gal, Y., Foster, A., Rainforth, T.: Prediction-oriented Bayesian active learning. In: Proceedings of the 26th International Conference on Artificial Intelligence and Statistics. Proceedings of Machine Learning Research, vol. 206, pp. 7331–7348 (2023), https://proceedings.mlr.press/v206/bickfordsmith23a.html
3. Boucheron, S., Lugosi, G., Massart, P.: Concentration Inequalities: A Nonasymptotic Theory of Independence. Oxford University Press (2013). https://doi.org/10.1093/acprof:oso/9780199535255.001.0001
4. Brier, G.W.: Verification of forecasts expressed in terms of probability. Monthly Weather Review **78**(1), 1–3 (1950). https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2
5. Cohn, D.A., Ghahramani, Z., Jordan, M.I.: Active learning with statistical models. Journal of Artificial Intelligence Research **4**, 129–145 (1996). https://doi.org/10.1613/jair.295
6. DePaul University Economics Data Archive: LendingClub loan data, https://bigblue.depaul.edu/jlee141/econdata/LendingClub_LoanData/, accessed 4 November 2026
7. Holm, S.: A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics **6**, 65–70 (1979). https://doi.org/10.2307/4615733
8. Huang, Z., Bickford Smith, F., Rainforth, T.: Loss-driven Bayesian active learning. In: Proceedings of the 29th International Conference on Artificial Intelligence and Statistics. Proceedings of Machine Learning Research, vol. 300, pp. 5140–5148 (2026), https://proceedings.mlr.press/v300/huang26b.html
9. Keswani, V., Mehrotra, A., Celis, L.E.: Fair classification with partial feedback: An exploration-based data collection approach. In: Proceedings of the 41st International Conference on Machine Learning. Proceedings of Machine Learning Research, vol. 235, pp. 23547–23576 (2024), https://proceedings.mlr.press/v235/keswani24a.html
10. Kirsch, A., van Amersfoort, J., Gal, Y.: BatchBALD: Efficient and diverse batch acquisition for deep Bayesian active learning. arXiv:1906.08158 (2019). https://doi.org/10.48550/arXiv.1906.08158
11. Lakkaraju, H., Kleinberg, J., Leskovec, J., Ludwig, J., Mullainathan, S.: The selective labels problem: Evaluating algorithmic predictions in the presence of unobservables. In: Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. pp. 275–284 (2017). https://doi.org/10.1145/3097983.3098066
12. MacKay, D.J.C.: A practical Bayesian framework for backpropagation networks. Neural Computation **4**(3), 448–472 (1992). https://doi.org/10.1162/neco.1992.4.3.448
13. Morato, P.G., Andriotis, C.P., Khademi, S.: ConBatch-BAL: Batch Bayesian active learning under budget constraints. arXiv:2507.04929 (2025). https://doi.org/10.48550/arXiv.2507.04929
14. Pham, T., Kottke, D., Krempl, G., Sick, B.: Stream-based active learning for sliding windows under the influence of verification latency. Machine Learning **111**(6), 2011–2036 (2022). https://doi.org/10.1007/s10994-021-06099-z

15. SAS Institute: Home equity data set. SAS example datasets, https://support.sas.com/documentation/onlinedoc/viya/exampledatasets/home_equity.csv, accessed 4 November 2026
16. Tomanek, K., Hahn, U.: A comparison of models for cost-sensitive active learning. In: Coling 2010: Posters. pp. 1247–1255 (2010), https://aclanthology.org/C10-2143/
17. Wei, D.: Decision-making under selective labels: Optimal finite-domain policies and beyond. In: Proceedings of the 38th International Conference on Machine Learning. Proceedings of Machine Learning Research, vol. 139, pp. 11035–11046 (2021), https://proceedings.mlr.press/v139/wei21a.html
18. Wilson, E.B.: Probable inference, the law of succession, and statistical inference. Journal of the American Statistical Association **22**(158), 209–212 (1927). https://doi.org/10.1080/01621459.1927.10502953
19. Yan, S., Chaudhuri, K., Javidi, T.: Active learning with logged data. In: Proceedings of the 35th International Conference on Machine Learning. Proceedings of Machine Learning Research, vol. 80, pp. 5521–5530 (2018), https://proceedings.mlr.press/v80/yan18a.html
20. Yeh, I.C., Lien, C.h.: The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. Expert Systems with Applications **36**(2), 2473–2480 (2009). https://doi.org/10.1016/j.eswa.2007.12.020
21. Yu, K., Bi, J., Tresp, V.: Active learning via transductive experimental design. In: Proceedings of the 23rd International Conference on Machine Learning. pp. 1081–1088 (2006). https://doi.org/10.1145/1143844.1143980