深度视觉与文本任务外部验证报告

2026-11-11 | DC-PRISM / supplement-v13 的本机外部适配

本轮已完成两类公开任务的完整主动学习曲线。模型为冻结的预训练深度编码器加重新训练的非线性分类头；尚不构成端到端微调或完整多分类标准基准复现。

结论：两个任务的测试复用均明显为正，早期运气对照差也均达到实质水平；但“两个任务都随阶段减弱”的联合预测未通过，也没有证实策略相对事前 oracle 的差距已经小于实质阈值。现有证据足以支持前两项有范围限制的发现，不能称为 v13 全部主张的验证成功。

一、先看登记预测

预测	运行前判据（简写）	结果
H1	两个任务的整条曲线测试复用均为正（联合区间下界 > 0）	成立
H2	两个任务的早期运气为正，且早期大于后期；四个联合区间下界均 > 0	不成立
H3	两个任务的全部策略均实质落后于测试 oracle；且各有至少一策略相对事前 oracle 的联合区间上界 ≤ 0.0005	不成立

“不成立”表示登记的联合判据没有全部满足，不能自动推导其反面。H3 使用上界证明差距小于阈值；仅仅检验不显著并不算通过。

二、完成规模与本机消耗

24 条正式轨迹（2 任务 × 12 种子），每条 30 步，6 种方法，共 4,464 个学习曲线评分点。正式运行用时 32.4 分钟。PyTorch 训练过程显存分配峰值 0.31 GiB（不含桌面和驱动占用）；本机 RTX 5060 Laptop 总显存约 8 GiB。

五个 Claude 本地提交已按文件树核验导入 GitHub 研究分支，包含 v12/v13 代码、协议、汇总指标、论文版本及已授权公开的内部审稿笔记。v13 的 12 张保存统计表重新计算后全部匹配。原始数据实验没有重新运行。

三、实验设计与信息隔离

项目	设定
视觉任务	CIFAR-10 猫/狗二分类；MobileNetV3-Small 的冻结图像特征，1,024 维。编码器约 152 万参数，含原分类器的完整模型约 250 万参数。
文本任务	AG News Business/Sci-Tech 二分类；冻结 MiniLM-L6，约 2,271 万参数，384 维均值池化特征，文本最多 128 token。
统一学习器	只用辅助集拟合 PCA/白化至 32 维；32 隐单元 ReLU 分类头，每次从共同初始化重新拟合 60 步全批 Adam。所有 oracle 的搜索和训练预算相同。
曲线预算	68 个初始标签；每步 40 个新候选中取 10 个，30 步后 368 标签；事前 oracle 使用 32 份标签复本。
每条轨迹的数据角色	官方训练集内：辅助集 2,000、验证集 512、参考集 256、初始历史 68、候选流 1,200，全部互斥；官方测试集抽 512 个记录评分。
结果模型与基线	GBDT 只用辅助集标签拟合；Random、Uncertainty、CoreSet 三个策略。基线集合与 v13 的五策略集合不同。

三种 oracle 的选择规则

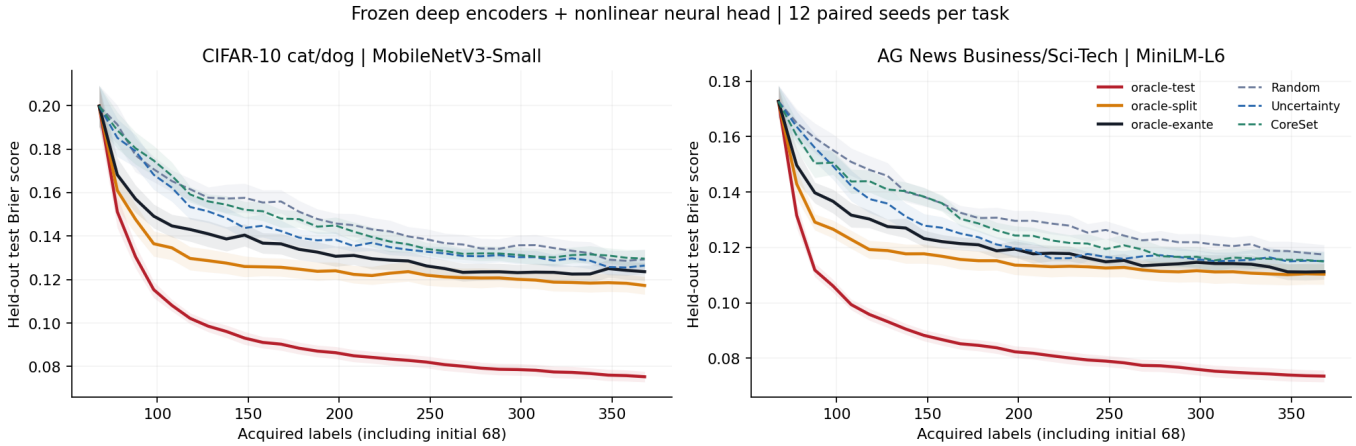
测试 oracle：用候选真实标签，在测试集上贪心选样。拆分 oracle：同样使用候选真实标签，但在独立验证集上选样。事前 oracle：候选标签由辅助集结果模型产生的 32 个伯努利复本替代，在验证集上按平均损失选样，选定后才加入真实标签。

各方法沿自己的轨迹累计标签，所有曲线用同一测试集的真实标签评分。整条曲线损失为第 1-30 步 Brier 的均值；早期为第 1-10 步，后期为第 21-30 步。

隔离核验：各角色索引互斥，预处理和结果模型不读取验证/测试标签；视觉二分类子集无精确像素重复，文本提取前移除了 2 条精确重复文本。未系统排查近重复和预训练语料污染。

协议与源代码在本地正式运行前冻结。GitHub 归档发生在启动后、检查正式端点前；这不属于前瞻性的公开预注册。所有 24 条轨迹按固定种子完成，无端点窥视、无追加种子。

四、完整学习曲线与整段平均结果



图中阴影是跨种子的标准误，仅用于描述；正式检验使用下表的多重比较校正区间。分数越低越好。

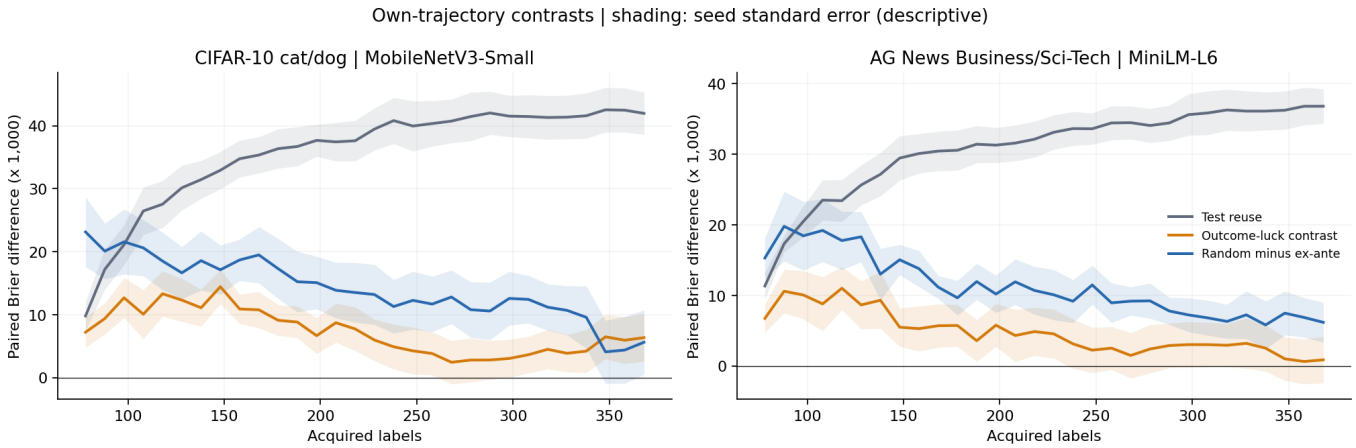
任务	测试 oracle	拆分 oracle	事前 oracle	Random	Uncertainty	CoreSet
文本：商业 / 科技	84.89	115.67	120.43	131.64	124.50	127.43
视觉：猫 / 狗	89.65	125.37	132.66	146.75	140.58	144.43

表内所有数字的单位均为 Brier × 1,000。对照差值大于零，表示后者的测试损失更高。

任务	整段分量	均值 [联合 95% 区间]	实质为正？
视觉：猫 / 狗	复用	35.73 [27.04, 44.41]	是
视觉：猫 / 狗	运气对照差	7.28 [-0.50, 15.06]	未证实
文本：商业 / 科技	复用	30.78 [23.87, 37.70]	是
文本：商业 / 科技	运气对照差	4.75 [-3.44, 12.95]	未证实

复用 = 拆分 oracle - 测试 oracle；运气对照差 = 事前 oracle - 拆分 oracle。两者之和加上“策略 - 事前 oracle”，恰好等于“策略 - 测试 oracle”。这是沿各自轨迹的算术分解，不能直接视为已识别的总体因果分解。

五、早晚阶段与策略差距



图中剩余差距固定以 Random 为锚，避免按结果选择最佳策略。

任务	对照量	均值 [联合 95% 区间]	为正？
视觉：猫 / 狗	早期运气	11.23 [4.42, 18.03]	是
视觉：猫 / 狗	早期 - 后期运气	6.86 [1.07, 12.64]	是
文本：商业 / 科技	早期运气	8.17 [0.81, 15.53]	是
文本：商业 / 科技	早期 - 后期运气	5.91 [-0.15, 11.98]	未证实

任务	oracle	全部策略实质落后？	至少一策略已证实差距 ≤ 阈值？
视觉：猫 / 狗	测试	是	未证实
视觉：猫 / 狗	拆分	未证实	未证实
视觉：猫 / 狗	事前	未证实	未证实
文本：商业 / 科技	测试	是	未证实
文本：商业 / 科技	拆分	未证实	未证实
文本：商业 / 科技	事前	未证实	未证实

正式检验：以轨迹种子为配对单位；整段分量 4 个端点、早期及早晚差 4 个端点、策略差距 18 个端点，分别做 Bonferroni 双侧联合区间。登记判定以这些区间为准；另存的 Holm 单侧 p 值是补充结果，不能替代主判据。实质阈值 0.0005 Brier。

六、证据边界与可复现材料

本轮把 v13 的三 oracle、完整曲线和信息隔离设计移到了两个视觉/文本任务。它提供的是“冻结深度表示 + 非线性头”的外部适配证据，不能替代主干网络端到端微调、完整多分类任务或 CDALBench 原配置的复现。

事前 oracle 依赖用额外辅助标签拟合的结果模型。所谓运气对照差受该模型误差、有限标签复本、贪心搜索以及后续轨迹变化共同影响；没有证明任何策略都无法获得这部分收益。负值或区间包含零均如实保留。

两个任务无法检验跨数据集噪声相关规律。置信区间主要描述给定数据集、预训练表示、学习器及划分规则下的种子随机性，不能升级为对总体或任意深度模型的覆盖保证。没有用本轮结果重写或撤回原论文中的主张。

保存材料

GitHub 包含：原始五提交到发布提交的映射；v12/v13 冻结协议、代码和结果；压缩指标内容审计；v13 统计重算匹配记录；本轮协议与冻结哈希、模型/数据版本、逐轨迹指标与划分哈希、联合区间、预测核对、完整曲线和复现说明。

原工作目录及未提交论文修改保持原样。GitHub API 导入会产生新的提交编号；每个对应快照的 Git 文件树均与原提交相同。原始个体数据、预训练权重与深度特征缓存未上传。

模型与数据来源（Hugging Face）

MobileNetV3-Small：https://huggingface.co/timm/mobilenetv3_small_100.lamb_in1k

MiniLM-L6：https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2

CIFAR-10：https://huggingface.co/datasets/uoft-cs/cifar10

AG News：https://huggingface.co/datasets/fancyzhx/ag_news

仓库：Lanceashire/DC-PRISM。实验目录 experiments/external_v14；结果目录 results/external_v14。