supplement-v13 实验报告与阶段评估

完整学习曲线上的三种 oracle：测试复用与结果运气

本次情况·比上次好在哪里·目前支持的结论·研究主线与偏移·论文层次

整理：Claude

2026 年 11 月 11 日

一页结论

1. **本次做了什么**。为回应文献核查中发现的 Zhou 等（AISTATS 2021）——他们用独立验证集给 oracle 选样，从而避开测试复用——我们在**完整学习曲线**上比较了三种 oracle：在测试集上选样的“基准式”（CDALBench、BoSS 的做法）、在独立验证集上选样的“Zhou 式”、以及选样时看不到候选标签的“事前式”。8 个数据集 × 32 条轨迹，每条 30 步，另有 4 个数据集用 4 倍大的验证集各 16 条。协议运行前冻结，全部完成。
2. **结果**。4 条登记预测中 2 条成立、2 条不成立。成立的一条是全项目最关键的：所有策略都明显落后于基准式 oracle 的数据集为 8/8，落后于 Zhou 式为 6/8，落后于事前式只有 1/8。拆分评价集只去掉了测试复用，结论基本不变；把运气也去掉，结论在 7 个数据集上被推翻。不成立的是：在整条曲线上，运气只在 3/8 个数据集达到实质水平，也不再随标签噪声变化——它集中在学习曲线最前面，标签多了以后就消失。
3. **比上次好在哪里**。上一轮（v12）的“基准结论被推翻”主要靠描述性证据，登记的主预测只成立一半；这一轮在**完整学习曲线**上、用**登记的预测**拿到了同样方向的结论，并且直接回应了“Zhou 已经拆分过评价集”的质疑。
4. **主线是否偏移**。项目整体经历过一次大的偏移（10 月底的算法论文 → 11 月 5 日起的评价方法学论文），此后主线稳定：*oracle* 差距中有多少是真正能争取的提升空间。这一轮没有改变主线，但改变了重心：从“偶然性下限随噪声变化”转向“测试复用与运气共同决定基准结论；运气是学习曲线早期现象”。
5. **论文层次**。目前是一篇方法严谨、实证扎实、概念新颖性一般的评价方法学论文，大致处于**CCF-B 会议的录用边缘**（DASFAA 把握约 30–35%），CCF-C 会议或相关 workshop 把握较大；要进入顶会（如 NeurIPS Datasets & Benchmarks、ICLR），还缺深度模型和标准基准上的完整复现。

目录

1 本次实验做了什么 **3**

1.1 动机 3

1.2 设计 3

1.3 执行情况 3

2 结果 **4**
2.1 登记预测核对 4
2.2 各数据集的分解 4
2.3 要点 5

3 比上次好在哪里 **5**
3.1 与 v12（11 月 10 日）对比 5
3.2 与项目早期相比 6

4 目前支持什么结论 **6**
4.1 有强证据支持（多轮独立研究、登记预测、稳健性检验） 6
4.2 有证据但有条件 6
4.3 不支持或已撤回 6

5 研究主线与偏移 **7**
5.1 当前主线（一句话） 7
5.2 是否偏移 7

6 论文大概是什么层次 **8**
6.1 评估 8
6.2 对应的发表层次 8

7 当前状态与待办 **8**

1 本次实验做了什么

1.1 动机

上一份阶段评估中的文献核查发现：Zhou 等（AISTATS 2021）的模拟退火 oracle 在独立验证集 D_V 上选样、在测试集 D_T 上报告，已经避开了测试复用；而 CDALBench（2024）和 BoSS（2026）原文明确在测试集上选样。审稿人很可能据此质疑："测试复用早就有人解决了"。另外，v12 的 E2 只在四个历史规模上各做单步，而基准报告的是整条学习曲线。本轮实验同时回答这两个问题：在完整学习曲线上，拆分评价集之后，还剩多少差距是运气?

1.2 设计

项目	设定
学习曲线	从 68 条已标注数据出发，每步从 40 个新候选中取 10 个，共 30 步，到 368 条；无风险约束、无延迟（池式基准设定）
三种 oracle	**基准式**：用候选的真实标签，在测试集上贪心选样；**Zhou 式**：同样用真实标签，但在与测试集等大的独立验证集上选样；**事前式**：在验证集上，按结果模型 $\hat{p}$ 生成的 32 个标签复本的平均损失选样，选样时看不到候选的真实标签
策略	Random、Uncertainty、BAIT-greedy、TargetVar-greedy、Fisher-cost（DC-PRISM 可能少取标签，会破坏统一横轴，故未纳入）
评分	所有曲线都在同一测试集上用真实标签评分；每条曲线沿自己的轨迹累积标签
分解（整条曲线平均 Brier）	测试复用 = Zhou 式 − 基准式；运气 = 事前式 − Zhou 式；剩余 = 最佳策略 − 事前式
规模	MAIN：8 数据集 × 32 条轨迹；BIGV：4 个大数据集，验证集为测试集的 4 倍，各 16 条
学习器	ℓ_2 逻辑回归（与主研究一致）
统计	配对 t、Bonferroni 联合区间与 Holm 校正；实质阈值 0.5×10^{-3} Brier

1.3 执行情况

- **流程**：协议与 7 个源文件的哈希在运行前冻结（本地提交 `97be653`），冒烟测试只用开发种子 99001，测时只用 99003；正式种子 171001–172016 均为首次使用。
- **运行**：MAIN 256 条轨迹用时 85 分钟，BIGV 64 条用时 20 分钟，全部 COMPLETE；结果提交为 `e6ead75`。
- **文件**：代码 `experiments/supplement_v13/`，协议 `configs/supplement_v13.json`，结果与预测核对 `results/supplement_v13/{MAIN,BIGV}/`。

2 结果

2.1 登记预测核对

编号	预测	结果	实际
P1	拆分评价集后，运气在噪声最高的 4 个数据集上都达到实质水平；运气占比与噪声正相关	不成立	4 个中 2 个（LC、PPDai）；全部 8 个中 3 个；Spearman 0.19
P2	测试复用占比在曲线后段（第 21–30 步）大于前段（第 1–10 步），至少 6/8	成立	8/8
P3	所有策略都明显落后于基准式 oracle：8/8；落后于 Zhou 式：$\geq 6/8$；落后于事前式：$\leq 4/8$	成立	8/8、6/8、1/8
P4	验证集放大 4 倍后，运气在至少 3/4 个数据集上达到实质水平	不成立	2/4（LC、UCI），4/4 为正

2.2 各数据集的分解

表 1　整条学习曲线上，基准式 oracle 对最佳策略的领先及其构成（逻辑回归，32 条轨迹/数据集；$\times 10^{-3}$ Brier）。最后一列：所有策略是否都明显落后于基准式/Zhou 式/事前式 oracle。

数据集	噪声	领先	复用%	运气%	剩余%	运气检验	复用% 前段 → 后段	都落后?
Spambase	0.052	7.9	58	23	18	实质	41→75	是/是/否
USPS	0.067	14.0	38	3	59	不确定	23→54	是/是/是
再入院	0.080	2.9	56	27	17	正，未达阈值	35→81	是/是/否
银行营销	0.091	4.6	54	17	29	正，未达阈值	32→92	是/否/否
HMEQ	0.097	4.9	66	3	31	不确定	38→103	是/否/否
PPDai	0.106	4.5	35	32	33	实质	23→50	是/是/否
UCI Credit	0.136	7.0	45	19	36	正，未达阈值	28→71	是/是/否
LendingClub	0.143	5.3	50	31	19	实质	30→87	是/是/否

注：后段 HMEQ 的复用占比超过 100%，是因为后段运气为负值（事前式略好于 Zhou 式），属于抽样波动。“最佳策略”按数据集事后选出，属描述性。

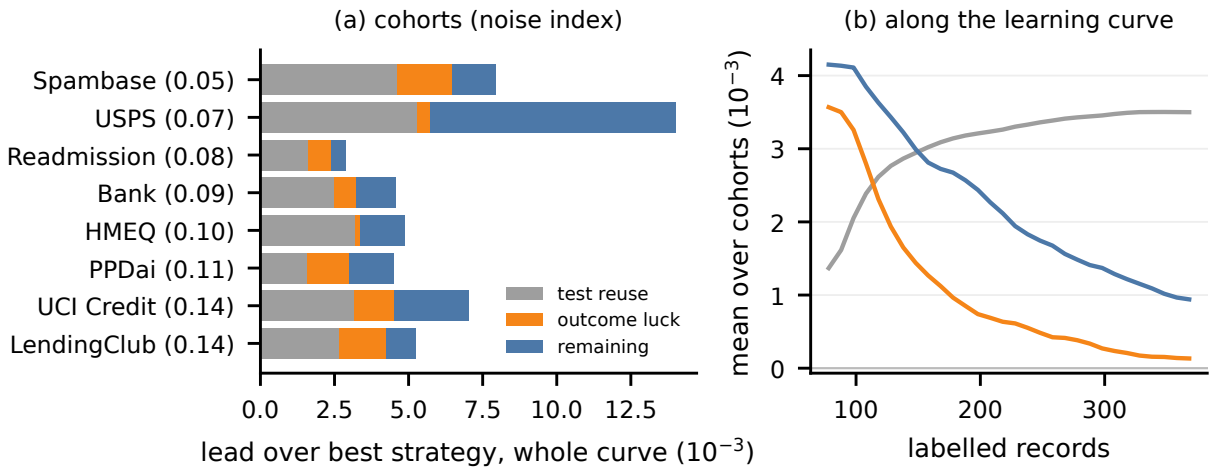


图 1　(a) 各数据集整条曲线上基准式 oracle 领先的构成：测试复用（灰）、运气（橙）、剩余（蓝）。(b) 三部分沿学习曲线的变化（各数据集平均，三步滑动平均）。运气在最初约 3.5×10^{-3}，到 200 条左右基本消失；测试复用一路上升。

2.3　要点

1. **结论被改变，而且是登记的。**对照基准式 oracle，40/40 个“数据集–策略”对都明显落后；对照 Zhou 式，36/40；对照事前式，17/40（8 个数据集中只有 USPS 仍然全部落后）。
2. **测试复用是整条曲线上最大的一块**（35–66%），而且越往后越大（8/8）。验证集放大 4 倍后，复用缩小 28–52%，说明它主要来自在有限评价集上选样的噪声。
3. **运气是学习曲线早期的现象。**前 10 步里，运气占 Zhou 式 oracle 领先的 31–71%（信贷、再入院与营销数据集）；后期基本为零。所以整条曲线平均下来，它只在 3/8 个数据集达到实质水平，而且不再随噪声变化。
4. **近确定标签上，oracle 的领先大多是真的。**USPS 上剩余部分占 59%，所有策略对三种 oracle 都明显落后——与单步研究一致。

3　比上次好在哪里

3.1　与 v12（11 月 10 日）对比

问题	v12 的状况	v13 之后	变化
“基准结论被改变”的证据	主要是描述性的（逐点区间）；登记主预测只成立一半	完整学习曲线上，登记预测 P3 成立（8/8→6/8→1/8）	**变强**
与 Zhou 2021 的关系	没有比较，审稿人会说“复用早已解决”	直接比较：拆分评价集后结论在 6/8 个数据集上仍成立，必须同时去掉运气	**新增**
单步 vs 完整曲线	只有四个位置的单步	30 步完整轨迹，每种方法沿自己的轨迹累积标签	**新增**
测试复用随曲线变化	单步中描述性观察	登记预测成立（8/8）	变强

问题	v12 的状况	v13 之后	变化
验证集大小	未检验	4 倍验证集：复用缩小，运气仍为正	新增
运气随噪声的规律	单步中稳健（Spearman 0.81–0.88）	整条曲线上不成立（0.19）；运气集中在早期	**变弱**

3.2 与项目早期相比

阶段	主要主张	证据状况
10 月底–11/03	DC-PRISM 优于基线	真实数据新种子确认 1/12 显著；放弃
11/05–11/06	oracle 差距存在偶然性下限	估计量混用、只验证到 12 候选、没有基准层面的证据
11/10（v12）	残差稳健；后期基准结论可能是假象	四个漏洞补齐；基准证据为描述性
11/11（v13）	拆分评价集不够，去掉运气后基准结论改变	完整学习曲线上的登记证据；回应已有工作

4 目前支持什么结论

4.1 有强证据支持（多轮独立研究、登记预测、稳健性检验）

1. **oracle 报告的领先不能直接当作提升空间**。在 8 个数据集、单步与完整学习曲线、风险约束与无约束设定下，都有相当部分是任何策略拿不到的（测试复用 + 运气）。
2. **只拆分评价集不够**。按 Zhou 的做法拆分后，“所有策略都明显落后”在 6/8 个数据集仍成立；去掉运气后只剩 1/8（v13，登记）。
3. **在单步（以及学习曲线早期），运气占比随标签噪声上升**。跨数据集（两批新状态，Spearman 0.81–0.88）、数据集内注入噪声（3/3）、五种结果模型下都成立；近确定标签 10–16%，噪声大的信贷 50–60%。
4. **这些结论不是方法缺陷造成的**。穷举到 20 候选与贪心差 $\leq 0.11 \times 10^{-3}$；更强的事前搜索只多拿 0.5%；残差区间两端很窄。
5. **测试复用随学习曲线增大**。单步研究和完整曲线（登记，8/8）都显示后期报告差距的大部分是复用。

4.2 有证据但有条件

1. **近确定标签上 oracle 的领先大多是真的**（USPS：剩余 59%，对三种 oracle 都落后）——只在一个手写数字数据集上检验。
2. **信息代理只在匹配学习器时有用**——风险约束案例研究中的结论。

4.3 不支持或已撤回

1. **在整条学习曲线上运气随噪声变化**：不支持（v13 P1 不成立，Spearman 0.19）。
2. **运气在整条曲线上普遍达到实质水平**：不支持（3/8；放大验证集后 2/4）。
3. **DC-PRISM 普遍优于强基线**：不支持。
4. 早期说法“下限占比 79%”“独立正态上界”“领先 4.48→1.25”：已撤回。

5 研究主线与偏移

5.1 当前主线（一句话）

主动学习基准用 *oracle* 衡量提升空间，但 *oracle* 的领先中有两块是任何策略都拿不到的——在有限评价集上选样造成的测试复用，以及所获标签中的结果运气；前者随学习曲线增大，后者集中在曲线早期并随标签噪声增大；两块一起去掉之后，“实用策略明显落后于 *oracle*”这一基准结论在多数数据集上不再成立。

5.2 是否偏移

时间	主线	偏移性质
10 月底	风险约束、延迟反馈下的标签获取算法 DC-PRISM	起点
11/04–05	收益机制：事后提升空间多少可事前获得	**大偏移**：从算法转向机制，原因是算法在真实数据上没有稳定优势
11/05–06	oracle 差距存在偶然性下限	中等偏移：从“我们的场景”推广到“主动学习评价”
11/10	oracle 差距中有多少是提升空间：复用 + 运气	小调整：估计量统一，加入测试复用
11/11	同上；运气是早期现象，拆分评价集不够	**没有偏移**，重心调整：从“下限随噪声变化”转向“两块一起决定基准结论”

判断。 项目在 11 月 5 日前后发生过一次实质性偏移（算法 → 评价方法学），这是被证据推动的、合理的偏移；之后的一周主线稳定，每一轮实验都在加固同一个问题。需要注意两点：

- **应用场景与主线的张力**：风险约束、延迟反馈和 DC-PRISM 来自最初的信贷场景，现在只是案例研究；论文中这部分越来越像附录。如果继续加强基准方向，可以考虑进一步弱化或移出 DC-PRISM。
- **“运气”的地位下降**：v13 显示在整条曲线上测试复用比运气更大、更稳定。论文题目和摘要如果继续把“结果运气”放在核心位置，需要明确它主要是早期和单步现象。

6 论文大概是什么层次

6.1 评估

维度	水平	说明
实验规范与严谨度	高	冻结协议、登记预测、多重比较、穷举核验、负结果如实报告，明显高于同类会议论文
实证发现	中偏高	“拆分评价集不够、去掉运气后基准结论改变”是新的、对当前基准（CDALBench、BoSS）有直接含义的发现
概念与理论	低	完全信息价值、乐观偏差、测试集过拟合都已有人讲过；上下界证明简单
外部有效性	中偏低	表格数据、逻辑回归/单隐层网络、小候选池；没有深度视觉/文本模型和标准基准的完整复现
写作与一致性	中偏高	估计量已统一；但题目与摘要的重心需要随 v13 调整

6.2 对应的发表层次

目标	把握（主观）	理由
CCF-C 会议 / 相关 workshop	较高（60% 以上）	严谨度和发现都足够
DASFAA 等 CCF-B 会议	约 30–35%	录用边缘：严谨但概念新颖性一般；受众对主动学习评价不一定熟悉
数据挖掘/机器学习期刊（如 DMKD、TMLR 类）	中等	期刊更看重严谨与完整性，篇幅也允许写全；需要补深度模型
顶会（NeurIPS D&B、ICLR 等）	较低（<15%）	缺深度模型、标准基准完整复现和更强的理论

总体判断。 这是一篇 **CCF-B 会议边缘、CCF-C 稳妥**的评价方法学论文。从 11 月 10 日上午的约 15–20% 到现在的约 30–35%，提升来自两点：方法学漏洞全部补齐、拿到了登记的“基准结论被改变”证据。要再上一个层次，最有效的一步是在深度模型和一个标准基准（例如 CDALBench 的一个视觉任务）上复现“拆分评价集不够”的结论；但这需要 GPU 时间，在 11 月 25 日截稿前做完的可能性不大。

7 当前状态与待办

- **GitHub**：本地领先 5 个提交（v12 冻结、v12 结果、v12 论文、v13 冻结、v13 结果），尚未推送，等你确认。
- **论文**：按你的要求暂不改论文。英文修订稿在此之前已补引 Zhou 2021、Koshorek 2019、Capability Frontier，并加入了 v13 一节（16 页），这些改动尚未提交；中文稿只补了引文。如不需要可以撤回。
- **报告文件夹**：本报告、上一份阶段评估、v12 结果说明、改进计划、研究报告，以及 v12 的中英文论文 PDF。